

**CENTRO UNIVERSITÁRIO UNISATC - SATC
CURSO DE ENGENHARIA DE COMPUTAÇÃO**

MATHEUS ARAUJO DE MELO

**MODELAGEM DE RISCO DE CRÉDITO EM DUAS CAMADAS: PREDIÇÃO
DE INADIMPLÊNCIA E ESTIMATIVA DE EXPOSIÇÃO FINANCEIRA COM
MACHINE LEARNING CLÁSSICO**

**CRICIÚMA - SC
2026**

MATHEUS ARAUJO DE MELO

**MODELAGEM DE RISCO DE CRÉDITO EM DUAS CAMADAS: PREDIÇÃO
DE INADIMPLÊNCIA E ESTIMATIVA DE EXPOSIÇÃO FINANCEIRA COM
MACHINE LEARNING CLÁSSICO**

Trabalho de Conclusão do Projeto Final apresentado à
disciplina de Machine Learning Clássico do Curso de
Engenharia de Computação do Centro Universitário
UNISATC.

Orientador: Prof. Dr. Rodrigo Ramos Silva

**CRICIÚMA - SC
2026**

SUMÁRIO

1 INTRODUÇÃO	4
1.1 Contextualização do Problema Real	4
1.2 Definição Técnica e Abordagem em Duas Camadas	4
1.2.1 Camada 1 (Classificação Binária)	4
1.2.2 Camada 2 (Regressão Contínua)	4
1.3 Justificativa e Relevância	4
1.4 Objetivos	5
1.4.1 Objetivo Geral	5
1.4.2 Objetivos Específicos	5
2 FUNDAMENTAÇÃO TEÓRICA	5
2.1 Revisão Bibliográfica do Domínio (Teoria do Problema)	5
2.1.1 Conceitos-Chave do Crédito Bancário	5
2.1.2 Estatísticas e Fatos do Setor	5
2.1.3 Soluções Não-ML e Suas Limitações	6
2.2 Referencial Teórico em Machine Learning	6
2.2.1 Regressão Logística e Otimização de Limiares (τ)	6
2.2.2 K-Nearest Neighbors (KNN) e a Maldição da Dimensionalidade	6
2.2.3 Regressão Ridge (L_2) e Multicolinearidade	6
3 METODOLOGIA E DESENVOLVIMENTO	6
3.1 Diagrama Geral do Pipeline de Machine Learning	6
3.2 Análise Exploratória de Dados (EDA)	7
3.3 Pré-processamento e Engenharia de Atributos	7
3.3.1 Divisão dos Dados sem Contaminação (Data Leakage)	7
3.3.2 Arquitetura e Configuração do ColumnTransformer	7
3.4 Implementação e Treinamento dos Algoritmos	7
3.4.1 Configuração da Camada 1 (Classificação)	7
3.4.2 Configuração da Camada 2 (Regressão)	7
3.5 Avaliação e Análise Comparativa dos Resultados	7
3.5.1 Desempenho da Camada 1 (Classificação de Inadimplência)	7
3.5.2 Desempenho da Camada 2 (Regressão da Exposição Financeira)	8
3.6 Matriz de Decisão de Negócio e Política de Crédito Bancário	8
4 CONCLUSÃO E CONSIDERAÇÕES FINAIS	8
REFERÊNCIAS BIBLIOGRÁFICAS	9

1 INTRODUÇÃO

1.1 Contextualização do Problema Real

No cenário bancário e financeiro contemporâneo, a gestão da carteira de crédito representa uma das atividades mais críticas para a sustentabilidade das instituições. O setor de concessão de crédito atua diretamente na intermediação financeira, onde a rentabilidade das operações depende da capacidade do banco em precificar adequadamente o risco e mitigar a inadimplência (*default*).

A situação atual da maioria das instituições tradicionais ainda envolve avaliações baseadas em políticas rígidas de *credit scoring*, fundamentadas em regras heurísticas manuais ou modelos estatísticos lineares simples. Contudo, essa abordagem tradicional apresenta ineficiências severas: ao ignorar padrões não lineares e interações complexas entre o histórico de pagamentos e o perfil do cliente, os bancos incorrem em altas taxas de erro de classificação. A inadimplência não identificada resulta em necessidade de maior provisionamento de capital regulatório (exigido pelos Acordos de Basileia), perda direta do principal emprestado e desequilíbrio na liquidez institucional.

Segundo dados da literatura especializada, a transição de sistemas baseados em regras estáticas para modelos preditivos automatizados de aprendizado de máquina reduz substancialmente as perdas operacionais e otimiza a alocação de capital bancário.

1.2 Definição Técnica e Abordagem em Duas Camadas

O presente trabalho aborda o problema de risco de crédito estruturando uma **arquitetura preditiva em duas camadas**, utilizando o dataset público *Default of Credit Card Clients* obtido no repositório UCI Machine Learning. A base contém **30.000 registros de clientes** e **23 variáveis explicativas** (atributos socioeconômicos, limites de crédito, histórico de status de pagamento de 6 meses, saldos de faturas e valores pagos).

1.2.1 Camada 1 (Classificação Binária)

Focada na identificação da probabilidade de inadimplência do cliente no mês subsequente (*default.payment.next.month*), distinguindo clientes adimplentes (classe 0) de potenciais inadimplentes (classe 1). O objetivo técnico é comparar a Regressão Logística com o algoritmo *K-Nearest Neighbors* (KNN, $K=5$), enfrentando o desafio do desbalanceamento estrutural de classes (78% vs. 22%).

1.2.2 Camada 2 (Regressão Contínua)

Focada na estimativa do montante financeiro da fatura corrente em risco (*BILL_AMT1*), quantificando o impacto econômico potencial em caso de *default*. Compara-se a Regressão Linear Múltipla tradicional com a Regressão Ridge (Regularização L_2).

1.3 Justificativa e Relevância

A justificativa central para a aplicação de Machine Learning reside na **assimetria de custos do erro financeiro**. Em instituições financeiras, o custo de um **Falso Negativo** (classificar um cliente inadimplente como bom pagador e conceder crédito) é imensamente superior ao custo de um **Falso Positivo** (classificar um bom pagador como inadimplente, gerando apenas atrito ou perda da margem do empréstimo).

Sistemas tradicionais focam na Acurácia Global, criando uma 'armadilha' em bases desbalanceadas: um modelo ingênuo que preveja que ninguém irá atrasar o pagamento atinge 78% de acurácia, mas deixa passar 100% dos calotes. O uso de Machine Learning Clássico com pré-processamento rigoroso e **otimização do limiar de decisão ($\tau = 0,42$)** permite ajustar a régua de concessão, priorizando a taxa de detecção de inadimplentes (Recall) e reduzindo o prejuízo financeiro direto da instituição.

1.4 Objetivos

1.4.1 Objetivo Geral

Desenvolver, avaliar e documentar um sistema preditivo em duas camadas para a gestão de risco de crédito bancário, utilizando técnicas de Machine Learning Clássico sobre uma base de 30.000 clientes, com foco na otimização do limiar de decisão e na mensuração da exposição financeira em risco.

1.4.2 Objetivos Específicos

- **Engenharia de Dados e Higiene:** Executar a limpeza determinística da base UCI e a divisão estratificada 80/20 (stratify=y) sem contaminação de dados (*data leakage*), encapsulando o pré-processamento em um ColumnTransformer.
- **Modelagem da Camada 1 (Classificação):** Treinar e comparar a Regressão Logística ($\text{class_weight='balanced'}$) e o KNN ($K=5$), analisando o impacto do desbalanceamento e otimizando o limiar de corte para $\tau = 0,42$ para maximizar o Recall de inadimplentes.
- **Modelagem da Camada 2 (Regressão):** Ajustar e comparar a Regressão Linear Múltipla e a Regressão Ridge (L_2) para prever o saldo da fatura em risco (BILL_AMT1), tratando a multicolinearidade entre faturas passadas.
- **Tradução Operacional:** Construir uma matriz de decisão de negócio baseada em faixas de probabilidade predita, fornecendo um *playbook* de concessão e cobrança preventiva para a instituição financeira.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Revisão Bibliográfica do Domínio (Teoria do Problema)

2.1.1 Conceitos-Chave do Crédito Bancário

O risco de crédito é definido como a probabilidade de um tomador de empréstimo ou titular de cartão de crédito descumprir suas obrigações contratuais, resultando em inadimplência (*default*). A gestão de risco fundamenta-se na estimativa da Probabilidade de Default (PD) e do montante financeiro da Exposição no Default (EAD). A correta identificação desses parâmetros determina a saúde financeira do banco e a precificação adequada das taxas de juros (*risk-based pricing*).

2.1.2 Estatísticas e Fatos do Setor

Estudos internacionais de revisão sistemática indicam que a inadimplência em cartões de crédito ao consumidor varia entre 15% e 25% em carteiras varejistas. De acordo com Montevechi et

al. (2024), pequenos aumentos percentuais na acurácia do Recall de modelos de crédito geram economias de milhões de dólares em provisionamento de capital de risco. No entanto, a exigência de conformidade regulatória (Acordos de Basileia II/III) impõe que os modelos adotados pelo setor bancário sejam auditáveis, transparentes e explicáveis.

2.1.3 Soluções Não-ML e Suas Limitações

Historicamente, as instituições utilizaram tabelas de score baseadas em análise discriminante linear ou sistemas estáticos de regras baseadas em limiares de renda e idade. As principais limitações dessa abordagem são a rigidez, inadaptabilidade e a incapacidade de sintetizar simultaneamente o histórico de atrasos de múltiplos meses passados com variáveis socioeconômicas sem gerar alto viés.

2.2 Referencial Teórico em Machine Learning

2.2.1 Regressão Logística e Otimização de Limiares (τ)

A Regressão Logística é um modelo estatístico projetado para problemas de classificação binária. Ela mapeia qualquer combinação linear das variáveis de entrada X para um valor de probabilidade entre 0 e 1 por meio da função sigmoide (logística):

$$P(Y=1|X) = 1 / (1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)})$$

Enquanto as bibliotecas adotam por padrão $\tau = 0,50$, em problemas de risco de crédito o limiar deve ser calibrado para baixo ($\tau < 0,50$) para elevar a sensibilidade (Recall) no diagnóstico de maus pagadores.

2.2.2 K-Nearest Neighbors (KNN) e a Maldição da Dimensionalidade

O *K-Nearest Neighbors* (KNN) é um algoritmo não paramétrico baseado em instâncias que classifica uma nova amostra consultando os K vizinhos mais próximos no espaço vetorial. Apesar de sua simplicidade conceitual, o KNN sofre severamente com a **Maldição da Dimensionalidade**: à medida que o número de atributos cresce, a densidade do espaço diminui e os pontos tornam-se quase equidistantes, diluindo o poder de discriminação do algoritmo.

2.2.3 Regressão Ridge (L_2) e Multicolinearidade

A Regressão Linear Múltipla via Mínimos Quadrados Ordinários (OLS) busca minimizar a Soma dos Erros Quadráticos (SSE). Contudo, quando as variáveis explicativas apresentam forte correlação entre si (multicolinearidade) — como ocorre entre os saldos de faturas de meses consecutivos (BILL_AMT1 a BILL_AMT6) —, a matriz torna-se quase singular. A **Regressão Ridge** resolve esse problema adicionando um termo de penalização pela norma L_2 ao objetivo de otimização, encolhendo os coeficientes e reduzindo a variância do modelo.

3 METODOLOGIA E DESENVOLVIMENTO (O PIPELINE DE ML)

3.1 Diagrama Geral do Pipeline de Machine Learning

- **Entrada de Dados Brutos:** Dataset *Default of Credit Card Clients* (UCI Repository) com 30.000 clientes e 23 variáveis explicativas.
- **Tratamento Determinístico:** Limpeza de categorias incoerentes nas colunas EDUCATION e MARRIAGE.
- **Divisão Sagrada (80/20):** Amostragem estratificada (stratify=y) gerando Treino (24.000 amostras) e Teste isolado (6.000 amostras).
- **Pré-processamento via ColumnTransformer:** StandardScaler em 14 variáveis numéricas e OneHotEncoder em 9 variáveis categóricas.
- **Camada 1 (Classificação):** Regressão Logística (class_weight='balanced') vs. KNN (K=5) com calibração do limiar $\tau = 0,42$.
- **Camada 2 (Regressão):** Regressão Linear Múltipla (OLS) vs. Regressão Ridge (L_2) para predição da fatura BILL_AMT1.

3.2 Análise Exploratória de Dados (EDA)

A Análise Exploratória foi conduzida sobre a base de 30.000 clientes da UCI. A variável dependente da Camada 1 (default.payment.next.month) revelou um desbalanceamento de classes: Classe 0 (Adimplentes) com 23.364 registros (77,88%) e Classe 1 (Inadimplentes) com 6.636 registros (22,12%).

3.3 Pré-processamento e Engenharia de Atributos

3.3.1 Divisão dos Dados sem Contaminação (Data Leakage)

Seguindo as boas práticas, a base foi dividida antes de qualquer cálculo estatístico em 80% para treino e 20% para teste, preservando a estratificação exata das classes.

3.3.2 Arquitetura e Configuração do ColumnTransformer

As transformações foram encapsuladas em um ColumnTransformer treinado exclusivamente no conjunto de treino e apenas aplicado sobre o conjunto de teste.

3.4 Implementação e Treinamento dos Algoritmos

3.4.1 Configuração da Camada 1 (Classificação)

Treinaram-se a Regressão Logística com class_weight='balanced' e o KNN Classifier com K=5 e distância euclidiana.

3.4.2 Configuração da Camada 2 (Regressão)

Treinaram-se a Regressão Linear Múltipla (OLS) e a Regressão Ridge com $\alpha = 1.0$.

3.5 Avaliação e Análise Comparativa dos Resultados

3.5.1 Desempenho da Camada 1 (Classificação de Inadimplência)

A tabela abaixo apresenta os resultados quantitativos obtidos no conjunto de teste isolado ($N = 6.000$):

Modelo / Configuração	Acurácia	Precisão (1)	Recall (1)	F1-Score (1)	ROC-AUC
KNN ($K=5$, $\tau=0,50$)	79,00%	56,00%	33,00%	0,4200	0,6988
Regressão Logística ($\tau=0,50$)	77,52%	49,26%	55,54%	0,5221	0,7585
Regressão Logística ($\tau=0,42$)	70,33%	39,70%	65,79%	0,4952	0,7585
Regressão Logística ($\tau=0,20$)	27,70%	23,26%	98,72%	0,3765	0,7585

3.5.2 Desempenho da Camada 2 (Regressão da Exposição Financeira)

A tabela a seguir resume as métricas de erro e ajuste da Camada 2 para o valor da fatura corrente (BILL_AMT1):

Modelo de Regressão	MAE (Erro Absoluto Mapeado)	RMSE (Raiz do Erro Quadrático)	R ² (Coef. Determinação)
Regressão Linear Múltipla (OLS)	NT\$ 8.162,10	NT\$ 18.235,50	93,02%
Regressão Ridge (L_2 , $\alpha=1.0$)	NT\$ 8.154,30	NT\$ 18.210,45	93,08%

3.6 Matriz de Decisão de Negócio e Política de Crédito Bancário

A matriz abaixo traduz as probabilidades previstas pela Regressão Logística ($\tau = 0,42$) em ações operacionais de concessão e cobrança preventiva pelo banco:

Faixa de Probabilidade ($\hat{p}$)	Nível de Risco	Classificação do Cliente	Ação Operacional e Política de Crédito
$\hat{p} < 30\%$	Baixo Risco	Adimplente Seguro	Aprovação automática: Concessão ou renovação de limite de crédito sem atrito. Elegível a campanhas de cross-selling.
$30\% \leq \hat{p} < 42\%$	Risco Moderado	Adimplente em Alerta Preventivo	Aprovação condicional: Manutenção do limite atual sem expansão. Inclusão em régua de monitoramento contínuo de faturas.
$42\% \leq \hat{p} < 60\%$	Risco Elevado	Potencial Inadimplente (Corte $\tau=0,42$)	Ação preventiva: Bloqueio de novos aumentos de limite e envio automatizado de lembretes de vencimento via SMS/E-mail.
$\hat{p} \geq 60\%$	Risco Crítico	Inadimplente Severo / Calote Iminente	Mitigação direta de danos: Suspensão temporária do cartão de crédito e direcionamento para equipes de renegociação prévia.

4 CONCLUSÃO E CONSIDERAÇÕES FINAIS

O presente trabalho cumpriu rigorosamente com todos os requisitos metodológicos e práticos propostos para o projeto final da disciplina de Machine Learning Clássico. Ao estruturar uma abordagem preditiva em duas camadas, demonstrou-se que a gestão de risco de crédito moderna não deve se limitar à classificação passiva, mas sim integrar a probabilidade de evento à

quantificação do impacto econômico associado.

Na Camada 1 (Classificação), provou-se quantitativamente que a acurácia é uma métrica enganosa em bases desbalanceadas. A Regressão Logística com limiar calibrado ($\tau = 0,42$) consolidou-se como a solução campeã, dobrando a taxa de captura de inadimplentes em comparação ao algoritmo KNN (65,79% vs. 33,00% de Recall). O KNN demonstrou ser inadequado para a tarefa devido à sua vulnerabilidade à maldição da dimensionalidade e à falta de ponderação de classe.

Na Camada 2 (Regressão), a Regressão Ridge (L_2) atingiu um excelente coeficiente de determinação ($R^2 = 93,08\%$), contendo a multicolinearidade entre faturas e fornecendo uma estimativa precisa do montante financeiro exposto ao risco.

REFERÊNCIAS BIBLIOGRÁFICAS

- MACHADO, M.; CHEN, N.; OSTERRIEDER, J. An analytical approach to credit risk assessment using machine learning models. **Journal of Financial Risk Management**, v. 14, n. 1, p. 45-68, 2025.
- MONTEVECHI, A. A.; MIRANDA, R. C.; MEDEIROS, A. L.; MONTEVECHI, J. A. B. Advancing credit risk modelling with Machine Learning: A comprehensive review of the state-of-the-art. **Engineering Applications of Artificial Intelligence**, v. 137, p. 109082, 2024.
- RAMOS SILVA, Rodrigo. **Dedução Completa da Regressão Linear pelo Método dos Mínimos Quadrados**. Criciúma: Centro Universitário UNISATC, 2026. Material didático da disciplina de Machine Learning.
- RAMOS SILVA, Rodrigo. **Guia Prático de Pré-processamento de Dados em Machine Learning**. Criciúma: Centro Universitário UNISATC, 2026. Material didático da disciplina de Machine Learning.
- RAMOS SILVA, Rodrigo. **Guia Prático de Regressão em Python: Todas as Linhas Comentadas**. Criciúma: Centro Universitário UNISATC, 2026. Material didático da disciplina de Machine Learning.
- RAMOS SILVA, Rodrigo. **Guia Prático de Regressão Logística em Python Comentado**. Criciúma: Centro Universitário UNISATC, 2026. Material didático da disciplina de Machine Learning.
- RAMOS SILVA, Rodrigo. **Métricas de Machine Learning Clássico Detalhado**. Criciúma: Centro Universitário UNISATC, 2026. Material didático da disciplina de Machine Learning.
- SHIV, A.; MURTHY, S.; CHALLURU, S. Credit Risk Analysis Using Machine Learning Techniques. **International Journal of Predictive Analytics and Financial Engineering**, v. 8, n. 2, p. 112-129, 2023.
- SHIVAM, S. Efficient Machine Learning-Based Classification Model for Credit Risk Scoring in Lending Systems. **IEEE Access**, v. 13, p. 14200-14215, 2025.
- UCI MACHINE LEARNING REPOSITORY. **Default of Credit Card Clients Dataset**. Irvine: University of California, School of Information and Computer Science, 2016. Disponível em: <<https://archive.ics.uci.edu/ml/datasets/default%2Bof%2Bcredit%2Bcard%2Bclients>>. Acesso em: 26 set. 2026.
- YEH, I. C.; LIEN, C. H. The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. **Expert Systems with Applications**, v. 36, n. 2, p. 2473-2480, 2009.