



MODELAGEM DE RISCO DE CRÉDITO EM DUAS CAMADAS: PREDIÇÃO DE INADIMPLÊNCIA E ESTIMATIVA DE EXPOSIÇÃO FINANCEIRA COM MACHINE LEARNING CLÁSSICO



O Custo da Assimetria no Crédito Bancário

A Ilusão da Acurácia



Uma política estática que aprova todos os clientes acerta 78% das vezes, mas deixa passar 100% dos calotes.

A Balança do Risco

Falso Positivo
(Bloquear bom cliente):
Custo de atrito e
perda de margem.

Custo: Marginal

Falso Negativo
(Aprovar calote):
Perda total do
principal +
Provisionamento
regulatório (Basileia).

Custo: Catastrófico



A otimização de modelos de crédito não busca a Acurácia global, mas a mitigação direcionada do Falso Negativo (Maximizar Recall).

Estado da Arte vs. Realidade Operacional Bancária

Abordagem	Artigos de Referência	Tecnologias	Risco de Overfitting	Aplicabilidade Bancária
A Fronteira Experimental	Montevechi et al. (2024), Machado et al. (2025)	MLP / Deep Learning, Ensembles Complexos	Alto	Baixa (Falta de interpretabilidade frente a reguladores).
A Fronteira do Balanceamento	Shiv et al. (2023), Shivam (2025)	Random Forest, XGBoost, Oversampling/RUS, SHAP/LIME	Moderado	Alta (Equilíbrio entre poder preditivo e explicabilidade XAI).
O Baseline Acadêmico	Yeh & Lien (2009)	Regressão Logística, Regressão Linear Clássica	Baixo	Altíssima (Baseline padrão na indústria, totalmente explicável).

Nossa Escolha: Combinar a explicabilidade do Baseline com as táticas de **limiares de decisão** avançadas e **regularização matemática**, criando um sistema à **prova de caixas pretas**.

Higiene de Dados e a Firewall de Data Leakage

A Muralha do Split

Treino - 80%

N=24.000 (Estratificado 78/22)

- Aprende parâmetros:
 - StandardScaler (Média/Desvio para limites e saldos)
 - OneHotEncoder (Educação, Estado Civil)

Teste - 20%

N=6.000 (Estratificado 78/22)

- Apenas recebe a aplicação das transformações
- Restrito ao método `.transform()` sem aprendizado estatístico



Limpeza Determinística executada PREVIAMENTE: Padronização de valores não-documentados (0, 5, 6) em variáveis categóricas sem uso de inferência estatística global.

Camada 1: O Combate dos Classificadores

K-Nearest Neighbors (KNN)

Configuração: K=5, Distância Euclidiana.

Premissa: Baseado em instâncias e similaridade espacial.



Regressão Logística

Configuração: class_weight='balanced', max_iter=1000.

Premissa: Ponderação paramétrica que penaliza severamente o erro na classe minoritária.

Modelo	Accuracy	Precision (Inadimplente)	Recall (Inadimplente)	F1-Score (Inadimplente)	ROC-AUC (Global)
KNN (Threshold 0.5)	79,00%	56,00%	33,00%	42,00%	0,6900
Regressão Logística (Threshold 0.42)	70,33%	39,70%	65,79%	49,00%	0,7500

Diagnóstico da Falha: A Maldição da Dimensionalidade




Problema 1: Em 23 dimensões (idade, histórico, limites, pagamentos), o espaço vetorial torna-se extremamente esperso. A "vizinhança" deixa de fazer sentido geométrico.

Problema 2: Ausência de ponderação nativa. Como 78% da base é adimplente, a vasta maioria dos 5 vizinhos mais próximos tenderá a ser da classe majoritária, esmagando o diagnóstico do calote.


RESULTADO: O modelo KNN atuou como um aprovador ingênuo, sacrificando o Recall (33%). Inadequado para o negócio.

A Balança da Assimetria: Otimizando a Régua de Risco

Curvas de Precisão e Recall vs. Limiar (τ)



Limiar de Decisão (τ)



RECALL OTIMIZADO: 65,79%

Captura de 2 em cada 3 calotes iminentes, garantindo
fluxo de caixa sem congelar 72% da base saudável.

0 Impacto Operacional do Limiar Calibrado

Confusion Matrix $\tau=0.42$		
	Predito Adimplente	Predito Inadimplente
Real Adimplente	3347	1326
Real Inadimplente	454	873

True Positives: Fuga de capital evitada. Inadimplentes isolados antes da concessão.



True Negatives: Operação comercial saudável mantida.



False Positives: 0 "imposto" da segurança. Bons pagadores bloqueados temporariamente (risco tolerável em cenários de crédito restritivo).




False Negatives: Risco residual (calotes que ainda passam), minimizado cirurgicamente pela redução do limiar.



Camada 2: Dimensionando a Exposição Financeira

Identificar o risco é o Passo 1. O Passo 2 é prever o montante (BILL_AMT1) que será perdido.

O Desafio: Multicolinearidade



Faturas de meses consecutivos são altamente correlacionadas. Usar Regressão Linear Clássica (Mínimos Quadrados OLS) inflama a variância dos coeficientes, tornando a predição instável.

A Solução: Regressão Ridge / Norma L2


$$\textit{Min}(SSE) + \lambda \sum \beta^2$$

A aplicação da penalidade $\lambda = 1.0$ atua como um "amortecedor", ancorando os coeficientes em direção a zero e estabilizando o modelo de regressão para estimativas seguras de capital.

Contenção de Variância e Resultados da Exposição

Métrica 1: $R^2 = 93,08\%$

Métrica 2: MAE = NT\$ 8.154,30



Tradução de Negócios

O modelo consegue prever o tamanho do saldo devedor futuro com impressionante precisão de 93%. Isso permite ao banco calcular provisões de Basileia exatas por cliente, em vez de usar médias gerais que imobilizam capital desnecessário.

Matriz de Decisão Operacional

Faixa de Probabilidade	Nível de Risco	Classificação do Cliente	Ação Operacional e Política de Crédito
$p < 30\%$	Baixo Risco	Adimplente Seguro	Aprovação automática: Renovação automática e campanhas de cross-selling. 
$30\% \leq p < 42\%$	Risco Moderado	Alerta Preventivo	Manutenção de limites atuais, inclusão em régua de monitoramento.  
$42\% \leq p < 60\%$	Risco Elevado (Abaixo do Limiar 0.42)	Potencial Inadimplente	Bloqueio de novos aumentos, SMS preventivo.  
$p \geq 60\%$	Risco Crítico	Inadimplente Severo	Suspensão do cartão, mitigação de danos e direcionamento de cobrança (com base no valor predito na Camada 2). 

Síntese Científico-Operacional

Higiene e Rigor Científico

- Sem Data Leakage.
- Divisão 80/20 perfeitamente selada com ColumnTransformer.

Adaptação à Realidade (Camada 1)

- A matemática curvada ao negócio.
- Falha do KNN contornada.
- Acurácia descartada em prol de um Recall maximizado (65,79%) via $\tau=0,42$.

Explicabilidade Financeira (Camada 2)

- Multicolinearidade neutralizada por Regressão Ridge.
- Estimativa precisa de 93% da variância de capital em risco.

A gestão de risco de crédito não deve se limitar à classificação passiva. Um modelo transparente equilibra perfeitamente a proteção do capital institucional com o dinamismo operacional do mercado.